

一、选择题答案

1. B

【知识点】Lehmann-Scheffe定理

【解析】L-S定理的完整表述：若 Y_1 是完备充分统计量， $\phi(Y_1)$ 是 $g(\theta)$ 的无偏估计，则 $\phi(Y_1)$ 是 $g(\theta)$ 的唯一MVUE。

注意'唯一'二字：完备性保证了这种无偏估计的唯一性。

2. B

【知识点】F分布性质

【解析】若 $F = (X/m)/(Y/n) \sim F(m,n)$ ，其中 $X \sim \chi^2(m)$ ， $Y \sim \chi^2(n)$ ，则

$1/F = (Y/n)/(X/m) \sim F(n,m)$ (注意 m,n 互换！)

等价地： $F_{\alpha}(m,n) = 1/F_{1-\alpha}(n,m)$ 。

3. C

【知识点】充分统计量的充要条件

【解析】对于 $U[0,\theta]$ ，联合密度为 $(1/\theta)^n * I\{X_{(n)} \leq \theta\}$ ，由因子分解定理， $X_{(n)}$ 是充分统计量 (含 θ 的信息完全由最大值决定)。

$\bar{X}$ 不是充分统计量：给定 $\bar{X}$ ，样本中还有额外关于 θ 的信息 (比如各观测值的散布)。

4. C

【知识点】拟合优度检验自由度

【解析】拟合优度检验的自由度 = k (区间数) - 1 (概率之和为1的约束) - r (估计参数个数) = $k-1-r$ 。

若没有估计参数 (完全已知分布)，自由度为 $k-1$ 。

若估计了 r 个参数 (如正态分布的 μ 和 σ 就是 $r=2$)，自由度为 $k-1-2=k-3$ 。

5. B

【知识点】Fisher信息量的可加性

【解析】对于 n 个i.i.d.样本，联合密度为各因子之积，对数似然为各分量之和：

$$l(\theta) = \sum (\log f(X_i; \theta))$$

总信息量 = n * 单个样本信息量 $I(\theta)$ 。

这也是RCB公式中分母有 $n \cdot I(\theta)$ 的原因。

二、填空题答案

6. $\sigma^2/(2n)$

【解析】 $N(\mu, \sigma^2)$ 中，Fisher信息矩阵为对角矩阵：

$$I(\mu, \sigma) = \text{diag}(1/\sigma^2, 2/\sigma^2)$$

故 σ 的无偏估计的RCB = $[I^{-1}]_{22}/n = (\sigma^2/2)/n = \sigma^2/(2n)$

7. $r-1$; $n-r$

【解析】组间自由度=组数-1= $r-1$ ；组内自由度=总样本量-组数= $n-r$ 。

记忆：组间消耗 r 个均值参数（减去1因为有约束），组内消耗 $n-r$ （每组消耗 n_i-1 个，合计 $n-r$ ）。

8. $\Phi(\sqrt{n/(n-1)}*(c-\bar{X}))$

【解析】已知 $X_1|\bar{X} \sim N(\bar{X}, (n-1)/n)$ ，

$$P(X_1 \leq c | \bar{X} = \bar{x}) = P(N(\bar{x}, (n-1)/n) \leq c) = \Phi((c - \bar{x})/\sqrt{(n-1)/n})$$

$$= \Phi(\sqrt{n/(n-1)}*(c - \bar{x}))$$

9. $\chi^2(2)$

【解析】Wilks定理： $-2\log(\Lambda) \sim \chi^2(q)$ ， q =约束个数。

若 H_0 有2个约束，则渐近服从 $\chi^2(2)$ ，不是参数维数！

10. $\hat{\theta} = 1/\bar{X}$; θ^2/n

【解析】 $\text{Exp}(\theta)$ （率参数 θ ，均值 $1/\theta$ ）的MLE：

$$l(\theta) = n \log(\theta) - \theta \sum(X_i) \rightarrow \hat{\theta} = n/\sum(X_i) = 1/\bar{X}$$

$$l(\theta) = 1/\theta^2, \text{RCB} = \theta^2/n。$$

$$\text{Var}(\hat{\theta}) = \theta^2/n = \text{RCB}, \text{故为有效估计量。}$$

三、计算题解答

11.

【知识点】正态分布推断， σ 已知

【(1) 99% 双侧置信区间】

$$\sigma=200, n=25, \sigma/\sqrt{n} = 200/5 = 40$$

$$z_{0.005} = 2.576 \text{ (99\%置信区间用} z_{0.005} \text{)}$$

$$CI = (1050 - 2.576*40, 1050 + 2.576*40) = (1050-103.04, 1050+103.04) = (946.96, 1153.04)$$

【(2) 右侧 z 检验， $\alpha=0.05$ 】

$$H_0: \mu=1000 \text{ vs } H_1: \mu>1000$$

$$Z = (1050-1000)/(200/\sqrt{25}) = 50/40 = 1.25$$

拒绝域： $\{Z \geq z_{0.05} = 1.645\}$

$1.25 < 1.645 \rightarrow$ 不拒绝 H_0 ，没有显著证据表明均值高于1000元。

【(3) 双边检验p值】

$H_0: \mu=1000$ vs $H_1: \mu \neq 1000$ (双边)

$Z = 1.25$ (同上)

$p\text{值} = 2 * P(Z \geq 1.25) = 2 * (1 - \Phi(1.25)) = 2 * (1 - 0.8944) = 2 * 0.1056 = 0.2112$

在 $\alpha=0.05$ 下： $p\text{值}=0.2112 > 0.05 \rightarrow$ 不拒绝 H_0

在 $\alpha=0.01$ 下： $p\text{值}=0.2112 > 0.01 \rightarrow$ 不拒绝 H_0

结论：在两个显著性水平下均不能拒绝 H_0 。

12.

【知识点】均匀分布的MLE、完备充分统计量、均匀分布通用MVUE公式

【(1) MLE及无偏修正】

$L(\theta) = (1/\theta)^n$ ，当 $\theta \geq X_{(n)}$ 时有效

$L(\theta)$ 关于 θ 单调递减 $\rightarrow \hat{\theta} = X_{(n)}$

$E(X_{(n)}) = n * \theta / (n+1) \neq \theta \rightarrow$ 有偏

无偏修正： $\theta_{UMVUE} = (n+1)/n * X_{(n)}$ (方差最小无偏估计)

【(2) 证明 $X_{(n)}$ 是CSS】

充分性：联合密度 $= (1/\theta)^n * I\{X_{(n)} \leq \theta\}$ ，由因子分解定理， $X_{(n)}$ 是充分统计量

完备性：设 $E[u(Y)] = 0$ 对所有 $\theta > 0$ 成立，其中 $Y = X_{(n)}$

Y 的密度： $g(y; \theta) = n * y^{n-1} / \theta^n$ ， $0 \leq y \leq \theta$

$E[u(Y)] = \int_0^\theta u(y) * n * y^{n-1} / \theta^n dy = 0$

即： $\int_0^\theta u(y) * y^{n-1} dy = 0$ 对所有 $\theta > 0$

对 θ 求导（微积分基本定理）： $u(\theta) * \theta^{n-1} = 0$

因为 $\theta > 0$ ，故 $u(\theta) \equiv 0 \rightarrow X_{(n)}$ 是CSS

【(3) θ^2 的MVUE】

利用均匀分布通用公式： $u(Y) = g(Y) + Y * g'(Y) / n$

取 $g(\theta) = \theta^2$ ， $g'(\theta) = 2 * \theta$

$MVUE = Y^2 + Y * (2Y) / n = Y^2 * (1 + 2/n) = X_{(n)}^2 * (n+2) / n$

13.

【知识点】 $N(\mu_0, \theta)$ ，Fisher信息量，MVUE

【(1) 指数族验证】

$f(x; \theta) = (2 * \pi * \theta)^{-1/2} * \exp\{-(x - \mu_0)^2 / (2 * \theta)\}$

$$= \exp\{-(x-\mu_0)^2/(2\theta) - (1/2)\log(2\pi\theta)\}$$

$$\text{令 } p(\theta) = -1/(2\theta), K(x) = (x-\mu_0)^2, H(x)=0, q(\theta) = -(1/2)\log(2\pi\theta)$$

支撑 R 与 θ 无关 ; $p(\theta)$ 非常数 $\rightarrow$ 属于正则指数族

$$CSS = \sum (X_i - \mu_0)^2$$

【(2) MLE及有效性】

$$l(\theta) = -(n/2)\log(2\pi\theta) - (1/(2\theta))\sum (X_i - \mu_0)^2$$

$$dl/d\theta = -n/(2\theta) + \sum (X_i - \mu_0)^2/(2\theta^2) = 0$$

$$\rightarrow \theta_{\text{hat}} = (1/n)\sum (X_i - \mu_0)^2$$

$$\text{无偏性: } E(\theta_{\text{hat}}) = (1/n)n\theta = \theta$$

Fisher信息量 (负二阶导数) :

$$d^2(\log f)/d\theta^2 = n/(2\theta^2) - \sum (X_i - \mu_0)^2/\theta^3 \rightarrow l(\theta) = 1/(2\theta^2)$$

$$RCB = 1/(n \cdot l(\theta)) = 2\theta^2/n$$

$$\text{Var}(\theta_{\text{hat}}) = \text{Var}((1/n)\sum (X_i - \mu_0)^2) = (1/n^2)n \cdot \text{Var}(X - \mu_0)^2$$

$$= (1/n)[E((X - \mu_0)^4) - \theta^2] = (1/n)[3\theta^2 - \theta^2] = 2\theta^2/n$$

$$\text{Var}(\theta_{\text{hat}}) = RCB = 2\theta^2/n \rightarrow \text{MLE是有效估计量}$$

【(3) S^2 的有效性】

$$S^2 = (1/(n-1))\sum (X_i - \bar{X})^2$$

$$\text{Var}(S^2) = 2\theta^2/(n-1) \text{ (由 } \chi^2(n-1) \text{ 分布得)}$$

$$\text{有效性} = RCB/\text{Var}(S^2) = (2\theta^2/n)/(2\theta^2/(n-1)) = (n-1)/n$$

S^2 的有效性为 $(n-1)/n < 1$, 而 θ_{hat} 有效性为1 , MLE更有效。

14.

【知识点】Poisson分布, Rao-Blackwell定理, 超几何条件分布

【(1) CSS】

Poisson属于正则指数族, $K(x)=x$, 故 $T=\sum(X_i)$ 是CSS, $T \sim \text{Poisson}(n\theta)$

【(2) 无偏性】

$$E(\psi(X_1)) = P(X_1=k) = \theta^k e^{-\theta}/k! = g(\theta)$$

【(3) MVUE的计算】

$$E(\psi(X_1)|T=t) = P(X_1=k|T=t)$$

在 $T=t$ 条件下, X_1 的条件分布为超几何/二项分布。

具体地:

$$P(X_1=k, T=t) = P(X_1=k)P(\sum_{i=2}^n X_i = t-k)$$

$$= [\theta^k e^{-\theta}/k!] * [(n-1)^{t-k} \theta^{t-k} e^{-(n-1)\theta}/(t-k)!]$$

$$= \theta^t e^{-n\theta} / (k! (t-k)!) * (n-1)^{t-k}$$

$$P(T=t) = (n\theta)^t * e^{-(n\theta)} / t!$$

$$P(X_1=k|T=t) = [\theta^k * e^{-(n\theta)} / (k! * (t-k)! * (n-1)^{(t-k)}] / [(n\theta)^t * e^{-(n\theta)} / t!]$$

$$= t! / (k! * (t-k)!) * (n-1)^{(t-k)} / n^t$$

$$= C(t,k) * (1/n)^k * ((n-1)/n)^{(t-k)}$$

这是 $\text{Bin}(t, 1/n)$ 的概率！故

$$\text{MVUE} = E(I\{X_1=k\}|T=t) = C(t,k) * (1/n)^k * ((n-1)/n)^{(t-k)}$$

$$= C(T,k) * (1/n)^k * ((n-1)/n)^{(T-k)}$$